

《机器学习》 实验报告本

班 级

学 号

姓 名

指导教师

戴蕾

信息科学与工程学院

2025 年 6 月

《机器学习》实验报告

实验名称：实验报告 3：决策树（Decision Tree）—— Titanic 生存预测

实验地点：信息 318

所用工具软件及环境：Python 3.12；NumPy / Pandas / scikit-learn / Matplotlib / SciPy

一、实验目的

- 掌握决策树的基本原理（信息熵 / 基尼指数、信息增益、递归划分）及 Python 实现；
- 掌握缺失值处理、类别特征编码等数据预处理方法；
- 能够运用决策树完成 Titanic 生存预测任务，输出决策树与分类精度；
- 掌握用交叉验证寻找最佳树深度以缓解过拟合。

二、实验内容

针对 Titanic 数据集（891 名乘客，总体生存率 38.38%）构建决策树分类器，预测乘客是否生存，输出决策树结构与分类精度。加分项：数据探索分析、交叉验证寻找最佳树深度、特征重要性分析。

三、实验步骤

- 数据探索（EDA）：分析性别、舱位等级、年龄与生存率的关系；
- 数据预处理：性别编码为 0/1，年龄/票价用中位数填补缺失，登船港口众数填补并编码，构造家庭规模 $\text{FamilySize} = \text{SibSp} + \text{Parch} + 1$ ；
- 划分数据：按 75%/25% 分层划分训练集与测试集；
- 深度调优：对 $\text{max_depth} = 1 \sim 15$ 做 5 折交叉验证，选取最佳深度；
- 训练与评估：用最佳深度训练决策树，输出训练/测试精度、混淆矩阵；
- 模型解释：绘制决策树结构与特征重要性。

四、程序设计的核心代码

① 数据预处理

```
df['Sex'] = (df['Sex'] == 'male').astype(int)          # 性别编码
df['Age'] = df['Age'].fillna(df['Age'].median())        # 缺失值填补
df['Embarked'] = df['Embarked'].fillna(df['Embarked'].mode()[0])\
    .map({'S':0, 'C':1, 'Q':2})
df['FamilySize'] = df['SibSp'] + df['Parch'] + 1        # 特征构造
```

② 深度调优 + 决策树训练与可视化

```
# 5 折交叉验证选择最佳树深度
for d in range(1, 16):
    score = cross_val_score(DecisionTreeClassifier(max_depth=d),
                            Xtr, ytr, cv=5).mean()
best_depth = depths[np.argmax(cv_means)]
```

```
clf = DecisionTreeClassifier(max_depth=best_depth).fit(Xtr, ytr)
plot_tree(clf, feature_names=..., class_names=['遇难', '生存'], filled=True)
```

五、实验结果

5.1 数据探索分析

EDA 显示生存率与性别、舱位强相关：女性生存率 74.20%，远高于男性 18.89%；一等舱生存率 62.96%，明显高于三等舱 24.24%，印证了“妇女与高舱位乘客优先”。




图 1 性别、舱位、年龄与生存情况分析

5.2 最佳树深度

5 折交叉验证得到最佳树深度为 5，对应交叉验证精度 81.14%。深度过大时精度反而下降，体现决策树容易过拟合。

表 1 不同树深度的交叉验证精度

max_depth	5 折 CV 平均精度
1	79.34%
2	80.09%
3	80.84%
4	79.65%
5	81.14%
6	79.35%
7	79.80%
8	79.95%
9	80.54%
10	79.80%




图2 决策树深度调优曲线

5.3 决策树与分类精度

使用最佳深度 $\text{max_depth}=5$ 训练决策树，训练精度 85.03%，测试精度 77.13%，全量 5 折交叉验证精度 81.70%。决策树结构如下图，根结点首先按性别划分，与 EDA 结论一致。




图 3 Titanic 生存预测决策树 (max_depth=5)




图 4 测试集混淆矩阵

5.4 特征重要性

决策树给出的特征重要性（基尼重要性）排序如下，性别与票价/舱位是最重要的划分特征：

表 2 特征重要性排序

特征	重要性
性别	0.574
舱位等级	0.185
年龄	0.102
票价	0.090
家庭规模	0.046
兄弟姐妹/配偶数	0.002
父母/子女数	0.000
登船港口	0.000




图 5 特征重要性条形图

六、实验体会

本次实验我使用决策树完成了 Titanic 生存预测，深刻理解了决策树“基于特征递归划分、以信息增益/基尼指数选择最优划分”的思想。几点体会：①数据预处理至关重要，Titanic 数据存在大量缺失（Age、Cabin、Embarked），合理填补与特征构造（FamilySize）直接影响效果；②决策树高度可解释，树结构与特征重要性清晰地揭示了“性别→舱位/票价→年龄”的决策逻辑，与历史事实吻合；③决策树容易过拟合，不加限制时训练精度可达 98% 以上但测试精度下降，通过交叉验证选择 $\text{max_depth}=5$ 限制复杂度，使测试精度达到 77.13%，验证了正则化（剪枝/限深）对泛化能力的重要性。

八、教师评价

评分标准	分值	得分
整体任务完成度	20	
实验步骤清晰度	20	
算法设计合理度	20	
实验结果正确度	20	
心得体会深度	20	
合计	100	

教师签名：_____