

《机器学习》 实验报告本

班 级

学 号

姓 名

指导教师

戴蕾

信息科学与工程学院

2025 年 6 月

《机器学习》实验报告

实验名称：实验报告 7：支持向量机（SVM）

实验地点：信息 318

所用工具软件及环境：Python 3.12；NumPy / Pandas / scikit-learn / Matplotlib / SciPy

一、实验目的

- 掌握支持向量机（SVM）的基本原理（最大间隔、对偶问题、核技巧、软间隔）及实现；
- 理解 SMO 算法求解 SVM 对偶问题的过程；
- 掌握不同核函数与参数对 SVM 分类性能与决策边界的影响；
- 能够运用 SVM 完成二分类与多分类任务并进行可视化分析。

二、实验内容

- 对比练习 2（自实现 SMO 训练 SVM）与练习 3（基于 sklearn SVC）的实现区别与联系，并以表格总结各自涉及的参数；
- 在手写数字识别任务上用不同核函数训练 SVC 并对比精度；
- 在二分类（svmdata2）与多分类（Iris）数据上，对不同核函数、不同参数（C、 γ 、多项式阶数）的决策边界、背景色与支持向量进行可视化对比。

三、实验步骤

- 阅读练习 2/练习 3 源码，分析两种实现的算法流程与参数；
- 手写数字识别：将 32×32 文本图像转为 1024 维向量，训练 SVC 并评估不同核函数；
- 二分类可视化：标准化 svmdata2，训练不同核/参数的 SVC，绘制决策边界与支持向量；
- RBF 参数研究：在 $C \times \gamma$ 网格上训练 RBF-SVM，观察过拟合/欠拟合；
- 多分类可视化：在 Iris 上训练多分类 SVM，绘制决策区域背景色与支持向量。

四、练习 2 与练习 3 的区别和联系（要求 1）

4.1 联系

两者求解的都是同一个 SVM 模型：在软间隔意义下最大化分类间隔，最终决策函数均为 $f(x) = \text{sign}(\sum \alpha_i y_i K(x_i, x) + b)$ ，都依赖核函数把数据映射到高维空间，并且最优解都只与少数支持向量有关。

4.2 区别

表 1 练习 2 与练习 3 实现对比

对比项	练习 2：自实现 SMO	练习 3：sklearn SVC
-----	--------------	------------------

实现方式	纯 NumPy 手写完整 Platt SMO	调用 libsvm 封装的 SVC
求解算法	SMO：每次选两个 α_i 解析优化	libsvm 优化的 SMO (C/C++)
核函数	手写 linear / rbf 核矩阵	linear/poly/rbf/sigmoid 等内置
分类能力	二分类（多分类需 1-vs-rest 组合）	原生支持多分类(OvO)
代码量/速度	代码量大、Python 实现较慢	几行代码、底层 C 实现快
用途	理解 SVM 与 SMO 原理	工程应用、快速建模

4.3 各自涉及的参数

表 2 SVM/SMO 涉及的主要参数

参数	含义	出现位置
C	软间隔惩罚系数，越大越不容忍误分类	练习 2 / 练习 3
toler	KKT 条件容错率（迭代终止判据）	练习 2
maxIter	SMO 最大迭代轮数	练习 2
kTup/kernel	核函数类型（lin / rbf 等）	练习 2 / 练习 3
σ / gamma	RBF 核宽参数，控制单样本影响范围	练习 2(σ) / 练习 3(gamma)
degree	多项式核阶数	练习 3
alphas, b	对偶变量与偏置（训练得到的模型参数）	练习 2 / 练习 3

五、不同核函数与参数的对比分析（要求 2）

5.1 手写数字识别（不同核函数）

将练习 3 的手写数字数据（训练 1934 张、测试 946 张，10 类）转为 1024 维向量，用不同核函数训练 SVC，测试精度如下表。其中 多项式核 $\text{poly}(d=3)$ 表现最佳，精度 99.15%（注：RBF 核宽 γ 取值过大或过小都会显著降低精度，说明参数选择的重要性）。

表 3 不同核函数下手写数字识别精度

核函数 / 参数	支持向量数	测试精度
线性核 linear	786	98.52%
多项式核 $\text{poly}(d=3)$	887	99.15%
高斯核 rbf(默认 γ)	1012	99.05%
高斯核 rbf($\gamma=0.001$)	841	98.63%

5.2 二分类：不同核函数的决策边界

在非线性可分数据 svmdata2 上对比不同核函数的决策边界（实线为决策边界，虚线为间隔边界，空心圈为支持向量）：线性核无法刻画非线性边界，多项式核与高斯核能形成弯曲边界；当 rbf 的 C 、 γ 过大时边界过度贴合训练点，出现明显过拟合。

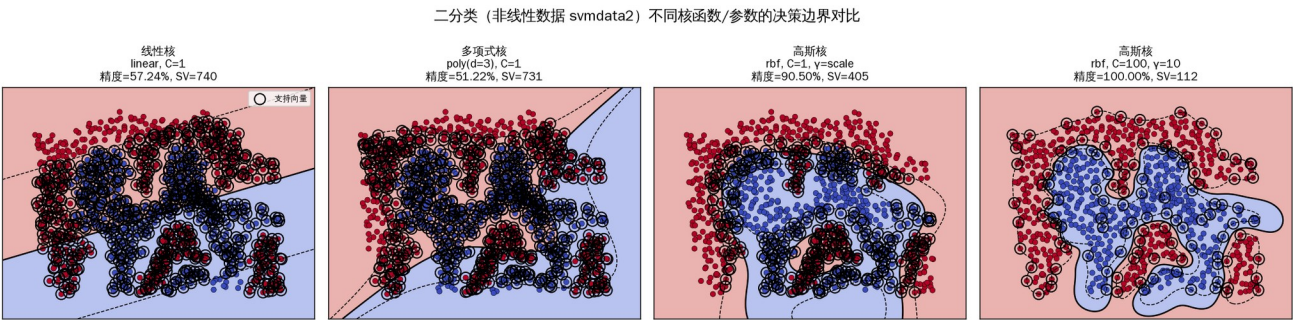


图 1 不同核函数/参数的二分类决策边界与支持向量

表 4 不同核函数二分类结果

核函数 / 参数	支持向量数	训练精度
线性核 linear, C=1	740	57.24%
多项式核 poly(d=3), C=1	731	51.22%
高斯核 rbf, C=1, γ =scale	405	90.50%
高斯核 rbf, C=100, γ =10	112	100.00%

5.3 RBF 核的参数 C 与 γ 的影响

固定 RBF 核，在 $C \times \gamma$ 网格上观察决策边界变化： γ 越大，单个样本影响范围越小，边界越“曲折”、越容易过拟合； C 越大，对误分类惩罚越重，间隔越窄、支持向量越少。二者共同决定模型复杂度，需通过交叉验证选取。

高斯核 (RBF) 不同惩罚参数 C 与核宽参数 γ 的影响




图 2 RBF 核惩罚参数 C 与核宽 γ 的影响 (3×3 网格)

5.4 多分类可视化 (Iris)

SVM 通过一对一(OvO)策略扩展到多分类。下图展示在 Iris 花瓣特征上，不同核函数的决策区域 (背景色)、样本点与支持向量 (空心圈)，并标注核函数、参数与精度：




图 3 SVM 多分类决策区域、背景色与支持向量

表 5 Iris 多分类不同核函数结果

核函数 / 参数	支持向量总数	精度
线性核 linear, C=1	31	95.33%
多项式核 poly(d=3), C=1	32	96.00%
高斯核 rbf, C=1, γ =scale	37	96.00%

六、实验体会

本次实验我从原理与实践两方面深入理解了 SVM。通过对比自实现 SMO (练习 2) 与 sklearn SVC (练习 3), 认识到二者求解的是同一最大间隔模型, 区别在于工程封装: 手写 SMO 帮助我理解了“每次挑选两个拉格朗日乘子 α 解析优化、用容错率判断 KKT 条件、最终模型只由支持向量决定”的过程; 而 sklearn 基于 libsvm 用几行代码即可完成训练并原生支持多分类。在核函数与参数实验中, 我直观地看到: ①核函数决定了决策边界的形状, 线性核只能画直线, poly/rbf 才能拟合非线性边界; ②惩罚参数 C 控制对误分类的容忍度, ③ RBF 的 γ 控制核宽, γ 过大会使边界过度贴合训练样本而过拟合。这些参数共同决定模型复杂度, 需要借助交叉验证在偏差与方差之间取得平衡。支持向量的可视化也让我理解了 SVM “稀疏解”的本质——决策边界只由少数关键样本支撑。

八、教师评价

评分标准	分值	得分
整体任务完成度	20	
实验步骤清晰度	20	
算法设计合理度	20	
实验结果正确度	20	
心得体会深度	20	
合计	100	

教师签名：_____